Exercicio 1.1

Eduardo Rios de Andrade Sousa – 2022087105

1) **Variancia do resíduo (Ruido inerente)**
   Essa é a variância presente nos próprios dados obtidos, que claramente fazem com que a saída do modelo seja afetada.
   Basicamente, ele é o ruído presente nos dados captados na vida real e que influenciam na saída esperada. Mesmo que você tivesse o modelo perfeito, o seu erro ainda teria uma componente dessa variância justamente pelo fato de que as medições dos dados apresentam imperfeições e captam ruídos além dos dados uteis.

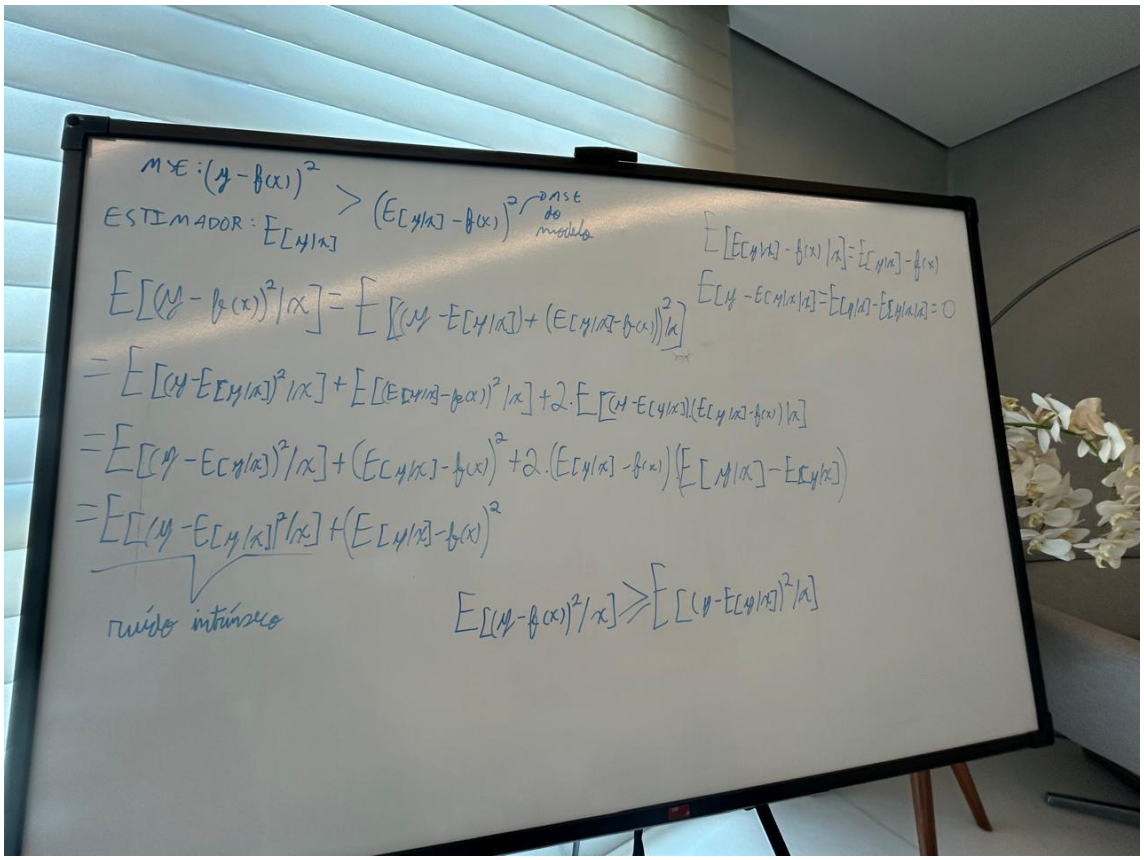

Da equação, podemos realmente ver que o erro do nosso modelo em relação aos dados coletados é limitado inferiormente por essa variância.

2) Viés ao quadrado

Essa medida nos diz o quão rígido o nosso modelo é. Ele mede a teimosia do modelo matemático obtido. Se o viés é alto, o modelo é extremamente rígido com regras que ele aprendeu, e acaba ignorando outros dados importantes que podem ser úteis, fazendo com que o erro aumente (casos de underfitting). Um viés baixo indica uma grande flexibilidade do modelo, o que faz com que ele capte vários padrões nos dados, inclusive os ruídos (caso de overfitting).

3) Variância do modelo

É o ponto de contrapartida do viés. Ele indica o quanto o modelo varia as acusações ao redor da esperança. Basicamente ele nos diz o contrário do viés (e também é alterado de forma contrária ao viés). Uma alta variância nos diz que o modelo é muito flexível e que qualquer mudança nos dados causa uma grande mudança na saída, pois os padrões aprendidos serão muito mais considerados. Uma variância baixa faz com que a saída não varie tanto, mas causa um viés alto.

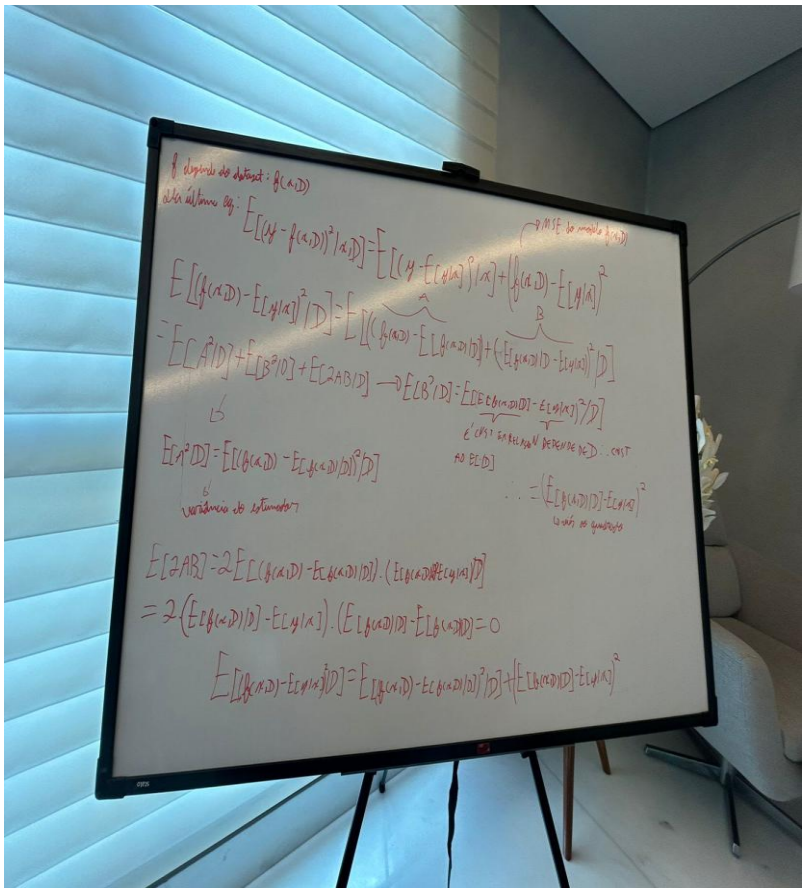

Da equação acima, vemos que ambos dependem do conjunto de dados que coletamos. Um mesmo modelo, com a mesma arquitetura, treinado do mesmo jeito sob diferentes datasets vão nos dar erros diferentes, justamente porque o

viés e a variância irão mudar de acordo com eles. Além disso, o intuito de diminuir o erro quadrático médio do modelo, de acordo com a equação, consiste em obter um viés mínimo e, a partir daí, minimizar o máximo possível a variância do modelo.